

Soofi Trainer — Demo-/Bedienungsskript

Dieses Skript führt einmal durchgängig durch die Bedienung des Soofi Trainers — von der Auswahl des Anwendungsfalls bis zum Start des Modelltrainings. Zusätzlich enthält es **Zwischenfragen-Blöcke**, die sich jederzeit im Gespräch einschieben lassen (Agentenkarten, Trainingsübersicht, Wissensinhalte).

Alle User-Sätze sind so formuliert, dass sie per Sprach- oder Texteingabe direkt in die Soofi-UI gegeben werden können. Agent-Reaktionen sind als Erwartungen in *kursiv* skizziert.

Der Soofi Trainer ist ein Demonstrator — die vorgeschlagenen Methoden und Modelle sind nicht immer fachlich optimal. Darauf kommt es in dieser Demo aber nicht an: Im Vordergrund steht, wie leichtgänglich Unternehmen künftig zu anwendungsspezifischen, souveränen Modellen auf Basis eigener Daten gelangen.

Spielt ruhig mit dem System, experimentiert mit eigenen Dialogen und lasst euch darauf ein — auch wenn etwas nicht auf Anhieb funktioniert, ist das überhaupt nicht schlimm. Im Hintergrund werden **Session-Logs** erstellt, die wir im Anschluss gerne gemeinsam auswerten. Dabei handelt es sich ausschließlich um **textuelle Protokolle** des Dialogverlaufs — es werden **keine Sprachaufzeichnungen** gespeichert.

0. Voraussetzungen

Backend & Zugang

- Das dockerisierte Backend läuft auf DFKI-Servern in Saarbrücken.
- Der Zugang erfordert ein aktives VPN. Dieses ist auf den iPads bereits eingerichtet — bei aktiver Verbindung erscheint rechts oben in der Statusleiste ein **VPN-Symbol**.
- Zur Ausfallsicherheit sind drei VMs parallel aufgesetzt, die sich im verwendeten Modell unterscheiden:

URL	Modell
https://soofi-1.mrk40.de	lokales Qwen3.5 122B
https://soofi-2.mrk40.de	lokales Qwen3.5 122B
https://soofi-3.mrk40.de	gpt-4o-mini (Cloud)

- Auf den iPads sind entsprechende **App-Icons auf dem Startbildschirm** hinterlegt — einfach antippen, kein manuelles Eingeben der URL nötig.

iPads — Nutzung & Rückgabe

- **Wichtig:** Die iPads sind gemietet und dürfen zu keinem Zeitpunkt unbeaufsichtigt liegen bleiben.
 - Rückgabe: Der Vermieter sammelt die Geräte am **letzten Messetag (Freitag) gegen 15:30 Uhr** wieder ein. Nach Messeende um 15:00 Uhr bleibt also nur eine halbe Stunde, um die iPads in den **Auslieferungszustand** zurückzusetzen.
 - Im Reset-Prozess wird ein **Bestätigungscode** an die hinterlegte Kontakt-E-Mail geschickt. Den iPad-Verantwortlichen bitte vorab telefonisch verständigen, damit der Code ohne Verzögerung weitergeleitet wird.
-

0.1 Begriffe zum Einstieg — Dataspace & Verwaltungsschale

Dataspace (Datenraum). Ein Dataspace ist ein föderierter, regelbasierter Raum, in dem Organisationen Daten oder Modelle untereinander anbieten und beziehen, ohne die Kontrolle darüber aufzugeben. Die Daten bleiben beim Anbieter; nur Metadaten (Kataloge) werden veröffentlicht, und der Zugriff wird über Nutzungsverträge (Policies) geregelt. Technische Basis ist in der Regel der **Eclipse Dataspace Connector (EDC)** — ein Open-Source-Connector nach IDSA-Standards, der Katalog, Vertragsverhandlung und Datenübertragung standardisiert. Typische Initiativen: Gaia-X, Catena-X, Manufacturing-X, Mobility Data Space, 8ra.

Verwaltungsschale (Asset Administration Shell, AAS). Die Verwaltungsschale ist der digitale Zwilling eines Assets (Maschine, Bauteil, Produkt, Software) im Sinne der **Industrie 4.0 / Plattform Industrie 4.0**. Sie bündelt alle relevanten Informationen eines Assets — Eigenschaften, Zustand, Dokumente, Fähigkeiten — in standardisierten **Submodels** (z.B. Digital Nameplate, Technical Data, Documentation) und stellt sie über eine einheitliche API (REST, OPC UA, MQTT) bereit. Umgesetzt wird das hier mit **Eclipse BaSyx**. Damit werden Assets maschinenlesbar, herstellerübergreifend austauschbar und über Dataspace-Grenzen hinweg verknüpfbar.

0.2 Nutzung im Soofi Trainer

Im Soofi Trainer dient der **Dataspace** als souveräne Bezugsquelle für Trainingsdatensätze. Der Dataset-Agent fragt zuerst den **EDC-Consumer** (über MCP) an und durchsucht den Katalog des angebundenen **EDC-Providers** nach passenden Datensätzen — z.B. für Materialforschung oder Engineering. Erst wenn der Dataspace nichts liefert, wird auf HuggingFace ausgewichen. So lässt sich demonstrieren, wie ein Unternehmen interne oder vertraglich geregelte Daten ins LLM-Training einbringt, ohne sie öffentlich verfügbar zu machen.

Die **Verwaltungsschale** liefert Soofi den fachlichen Kontext der Assets, um die es im Anwendungsfall geht. Der AAS-Stack (Eclipse BaSyx) hält Submodels zu typischen KMU-/

Engineering-Szenarien bereit (Maschinen, Bauteile, Datenblätter). Diese Informationen können von Agenten als strukturiertes Domänenwissen gelesen werden — etwa um Datensätze passgenau auf ein Asset zuzuschneiden, Trainingsdaten um Metadaten anzureichern oder später im Engineering-Copilot fundierte Antworten zur realen Anlage zu geben. Dataspace + Verwaltungsschale zusammen bilden damit die Brücke zwischen souveränem Datenaustausch und maschinenlesbarem Asset-Wissen, auf der das Soofi-Training aufsetzt.

1. Happy Path — vom Anwendungsfall bis zum Trainingsstart

1.1 Einstieg

User: Kannst du mir helfen, ein Modell für meinen Anwendungsfall zu spezialisieren?

→ Soofi fragt nach dem Anwendungsfall.

1.2 Anwendungsfall nennen

User: Ich brauche einen Assistenten zum Thema Compliance.

→ Soofi bestätigt „Compliance“ und fragt, ob nach Datensätzen gesucht werden soll.

1.3 Datensatzsuche — Dataspace zuerst

User: Ja, such mal nach Datensätzen.

→ Dataset-Agent wird aufgerufen (zuerst Eclipse Dataspace). Wenn nichts gefunden: Soofi schlägt HuggingFace als Fallback vor.

1.4 Datensatzsuche — HuggingFace

User: Ja, guck mal auf HuggingFace.

→ Soofi listet 5 Datensätze (z.B. `refusal-compliance-pairs`, `Akshata/autotrain-data-compliance`, ...).

1.5 Datensatz auswählen

User: Nimm den ersten Datensatz.

→ Soofi empfiehlt passende Basismodelle (Soofi 8B / 30B MoE / 120B MoE), jeweils mit kurzer Eignungs-Begründung (digitale Souveränität, Skalierung).

1.6 Basismodell auswählen

User: Nimm das Soofi 120B MoE.

→ Soofi schlägt Trainingsmethoden vor (z.B. RAG, SFT, DPO, LoRA, QLoRA) und fragt, welche verwendet werden soll.

1.7 Methode auswählen

User: Dann nehmen wir QLoRA.

→ Soofi fasst alle 4 Slots zusammen (Anwendungsfall, Datensatz, Basismodell, Methode) und fragt, ob das Training gestartet werden soll.

1.8 Training starten

User: Ja, starte das Training!

→ Training-Agent wird aufgerufen, das Seitenpanel öffnet die Trainingsübersicht (`training_view`). Soofi bestätigt: „Der Trainingsauftrag wurde gestartet.“

2. Zwischenfragen — jederzeit einschiebbar

Die folgenden Blöcke funktionieren an jedem Punkt im Gespräch. Nach der Beantwortung nimmt Soofi den Hauptfaden wieder auf (ggf. mit „Wo waren wir stehen geblieben?“).

2.A Agentenkarten anzeigen

User: Zeig mir die Agenten-Karten.

→ Seitenpanel öffnet `agent_cards` — 4 Karten: Interaction-, Advisor-, Training-, Dataset-Agent.

User: Schließ die Ansicht wieder.

→ Seitenpanel wird geschlossen.

2.B Trainingsübersicht öffnen/schließen

User: Öffne die Trainingsübersicht.

→ Seitenpanel `training_view` zeigt Phasen (Datenvorbereitung, Training, Evaluation) und Fortschritt.

User: Schließ die Trainingsübersicht wieder.

2.C Standortbestimmung im Dialog

User: Wo waren wir stehen geblieben? Was fehlt denn noch?

→ Soofi listet die gefüllten Slots (Anwendungsfall / Datensatz / Basismodell / Methode) und nennt den nächsten fehlenden.

2.D Wissensinhalte — Methodenvergleich

User: Kannst du die Methoden vergleichen? Was ist der Unterschied zwischen RAG, LoRA, QLoRA, SFT und DPO?

→ Advisor-Agent antwortet per RAG auf Basis von `rag_vs_fine_tuning.md`, `lora.md`, `qlora.md`, `dpo.md`. Quellen werden am Chatbeitrag angezeigt.

2.E Wissensinhalte — Basismodelle

User: Welche offenen Modelle kennst du? Kannst du sie miteinander vergleichen?

→ Advisor erklärt Soofi/8ra, OLMo, Mistral, Qwen, DeepSeek anhand `base_models.md` und `rag_vs_fine_tuning.md` (Souveränität, Transparenz, Lizenz).

2.F Wissensinhalte — 8ra-Initiative

User: Was kannst du mir über die 8ra-Initiative sagen?

→ Advisor antwortet aus `8ra_initiative.md` und `soofi-project.md` (EU-Mitgliedstaaten, IPCEI-CIS, BMW-Koordination).

2.G Wissensinhalte — RAG vs. Fine-Tuning

User: Wann nutzt man RAG, wann Fine-Tuning?

→ Advisor erklärt anhand `rag_vs_fine_tuning.md` — RAG für dynamisches Wissen, Fine-Tuning für Sprachstil/Format.

2.H Wissensinhalte — Use-Case-Beispiele

User: Welche Anwendungsfälle sind für Soofi typisch?

→ Advisor listet Beispiele aus `01_compliance_copilot.md`, `02_wissensmanagement.md`, `03_engineering_copilot.md`, `07_digital_product_passport.md`, `08_vergabe_assistent.md`, `09_verwaltungsassistent.md`.

3. Variationen für weitere Demo-Durchläufe

Anwendungsfall	Datensatzquelle	Basismodell	Methode
Compliance	HuggingFace	Soofi 120B MoE	QLoRA
Materialforschung	Eclipse Dataspace	Soofi 30B MoE	LoRA
Wissensmanagement	HuggingFace	Soofi 8B Dense	RAG
Engineering-Copilot	Eclipse Dataspace	Soofi 30B MoE	SFT

Tipp für Eclipse Dataspace: zuerst „such mal nach Datensätzen" sagen, bei Fehlanzeige gezielt nach Materialforschung im Dataspace fragen — der Dataset-Agent liefert dann den Katalog-Eintrag mit `counterPartyAddress`.

4. Zurücksetzen / neue Session

- **Zurücksetzen-Button** in der Soofi-UI drücken → startet eine frische Session.
- Alternativ: Browser-Tab schließen oder Seite neu laden → neue Session-ID.

5. Ausfallszenarien (gut für Demo-Robustheit)

- **Kein Dataspace-Treffer** → „Such mal auf HuggingFace" als Fallback.
- **Kein HuggingFace-Treffer** → alternative Begriffe vorschlagen lassen.
- **Advisor antwortet zu knapp** → „Kannst du das noch ausführlicher erläutern?"